

#机器人中的状态估计课后习题答案

完成人：高明

联系方式：

知乎：高明

微信：gaoming0901

2.概率论基础

2.5.1

假设 u, v 是相同维度向量, 请证明下面等式: $u^T v = \text{tr}(v u^T)$

solution:

$$u = (x_1, x_2, \dots, x_n)^T$$

$$v = (y_1, y_2, \dots, y_n)^T$$

$$u^T v = x_1 y_1 + x_2 y_2 + \dots + x_n y_n \quad \sum_{i=1}^n x_i y_i$$

$$u v^T = \begin{bmatrix} x_1 y_1 & \dots & x_1 y_n \\ \vdots & \ddots & \vdots \\ x_n y_1 & \dots & x_n y_n \end{bmatrix}$$

$$\text{tr}(u v^T) = \sum_{i=1}^n x_i y_i = u^T v$$

2.5.2

如果有两个相互独立的随机变量 x, y , 它们的联合分布为 $p(x, y)$, 请证明它们概率的香浓信息等于各自独立香浓信息的和:

$$H(x, y) = H(x) + H(y)$$

solution:

$$H(x, y)$$

$$= -E_{(x, y)}(\ln(f(x, y)))$$

$$= -\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) \ln(f(x, y)) dx dy$$

因为 x, y 独立

$$H(x, y)$$

$$= -\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x) f(y) [\ln(f(x)) + \ln(f(y))] dx dy$$

$$= -[\int_{-\infty}^{\infty} f(x) \ln(f(x)) dx] [\int_{-\infty}^{\infty} f(y) dy] - [\int_{-\infty}^{\infty} f(y) \ln(f(y)) dy] [\int_{-\infty}^{\infty} f(x) dx]$$

$$\int_{-\infty}^{\infty} f(x) \ln(f(x)) dx - \int_{-\infty}^{\infty} f(y) \ln(f(y)) dy$$

$$H(x) + H(y)$$

2.5.3

对于高斯分布的随机变量 $x \sim N(\mu, \Sigma)$, 请证明下面的等式：

$$\mu = E[xx^T] = \Sigma + \mu\mu^T$$

solution:

$$\Sigma$$

$$= E[(x - \mu)(x - \mu)^T]$$

$$= E[xx^T - x\mu^T - \mu x^T + \mu\mu^T]$$

$$= E[xx^T] - E(x)\mu^T - \mu E(x^T) + \mu\mu^T$$

$$\text{因为 } E(x) = \mu$$

$$\Sigma = E[xx^T] - \mu\mu^T$$

因此

$$E[xx^T] = \Sigma + \mu\mu^T$$

2.5.4

对于高斯分布的随机变量 $x \sim N(\mu, \Sigma)$, 请证明下面的等式：

$$\mu = E(x) = \int_{-\infty}^{\infty} xp(x)dx$$

solution:

$$E(x)$$

$$= \int_{-\infty}^{\infty} \frac{x}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right) dx$$

做变换：

$$y = x - \mu$$

$$\text{可得: } x = y + \mu$$

$$E(x)$$

$$= \int_{-\infty}^{\infty} \frac{y + \mu}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}y^T \Sigma^{-1}y\right) dy$$

$$= \int_{-\infty}^{\infty} \frac{y}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}y^T \Sigma^{-1}y\right) dy + \int_{-\infty}^{\infty} \frac{\mu}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}y^T \Sigma^{-1}y\right) dy$$

上式第一项由于奇函数在关于0对称空间积分为0

上式第二项扣除 μ 满足概率归一化条件

$$E(x) = \mu$$

2.5.5

对于高斯分布的随机变量， $x \sim N(\mu, \Sigma)$ ，证明下式：

$$\Sigma = E[(x - \mu)(x - \mu)^T] = \int_{-\infty}^{\infty} (x - \mu)(x - \mu)^T p(x) dx$$

solution:

$$E[(x - \mu)(x - \mu)^T]$$

$$= \int_{-\infty}^{\infty} \frac{(x - \mu)(x - \mu)^T}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right) dx$$

做代换 $y = x - \mu$

$$E[(x - \mu)(x - \mu)^T]$$

$$= \int_{-\infty}^{\infty} \frac{yy^T}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}y^T \Sigma^{-1} y\right) dy \dots <0>$$

下面参考文献【1】中公式(108)如下式：

$$\frac{\partial}{\partial X} (X^T B X) = B X + B^T X$$

上式中X是矩阵，向量算特殊矩阵，直接带入，向量表达式如下：

$$\frac{d}{dx} (x^T B x) = B x + B^T x \dots <1>$$

由于协方差矩阵是对称矩阵，根据等式<1>：

$$\frac{d}{dx} (x^T \Sigma^{-1} x) = \Sigma^{-1} x + \Sigma^{-T} x = 2 \Sigma^{-1} x \dots <2>$$

对于<2>式变换：

$$\frac{d}{dx} \left(-\frac{1}{2} x^T \Sigma^{-1} x\right) = \left(-\frac{1}{2}\right) (\Sigma^{-1} x + \Sigma^{-T} x) = -\Sigma^{-1} x$$

$$= x^T \Sigma^{-1} \dots <3>$$

将<3>式带入<0>式：

$$E[(x - \mu)(x - \mu)^T]$$

$$= \int_{-\infty}^{\infty} \frac{-y^T \Sigma}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}y^T \Sigma^{-1} y\right) d\left(-\frac{1}{2}y^T \Sigma^{-1} y\right)$$

$$= \int_{-\infty}^{\infty} \frac{-y^T \Sigma}{\sqrt{(2\pi)^N \det(\Sigma)}} d\left(\exp\left(-\frac{1}{2}y^T \Sigma^{-1} y\right)\right)$$

分步积分法：

$$E[(x - \mu)(x - \mu)^T]$$

$$= \frac{y^T \Sigma}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}y^T \Sigma^{-1} y\right) \Big|_{-\infty}^{+\infty} + \int_{-\infty}^{\infty} \frac{\Sigma}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}y^T \Sigma^{-1} y\right) dy$$

$$\sigma = 0 + \Sigma$$

$$\sigma = \Sigma$$

2.5.6

对于K个相互独立的高斯变量， $x_k \sim N(\mu_k, \Sigma_k)$ ，请证明它们的归一化积仍然是高斯分布：

$$\exp(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)) \equiv \eta \prod_{k=1}^K \exp(-\frac{1}{2}(x_k-\mu_k)^T \Sigma_k^{-1}(x_k-\mu_k)) \quad \eta$$

其中：

$$\Sigma^{-1} = \sum_{k=1}^K \Sigma_k^{-1}$$

$$\Sigma^{-1} \mu = \sum_{k=1}^K \Sigma_k^{-1} \mu_k$$

且 η 归一化因子。

solution:

随机变量 x_k 的概率密度函数如下：

$$f_k(x) = \frac{1}{\sqrt{(2\pi)^{N_k} \det(\Sigma_k)}} \exp(-\frac{1}{2}(x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k))$$

$$f_1(x) f_2(x) \dots f_K(x)$$

$$= \frac{1}{\sqrt{(2\pi)^{\sum_{k=1}^K N_k} \prod_{k=1}^K \det(\Sigma_k)}} \exp(-\frac{1}{2} \sum_{k=1}^K (x-\mu_k)^T \Sigma_k^{-1}(x-\mu_k))$$

将指数部分的求和号展开：

$$f_1(x) f_2(x) \dots f_K(x)$$

$$= \frac{1}{\sqrt{(2\pi)^{\sum_{k=1}^K N_k} \prod_{k=1}^K \det(\Sigma_k)}} \exp(-\frac{1}{2} (x^T (\sum_{k=1}^K \Sigma_k^{-1}) x - 2x^T (\sum_{k=1}^K \Sigma_k^{-1} \mu_k) + \sum_{k=1}^K \mu_k^T \Sigma_k^{-1} \mu_k)) \dots <0>$$

因为协方差矩阵是对称矩阵， $<0>$ 式中

$$(\sum_{k=1}^K \mu_k^T \Sigma_k^{-1}) x = x^T (\sum_{k=1}^K \Sigma_k^{-1} \mu_k)$$

因此：

$$f_1(x) f_2(x) \dots f_K(x)$$

$$= \frac{1}{\sqrt{(2\pi)^{\sum_{k=1}^K N_k} \prod_{k=1}^K \det(\Sigma_k)}} \exp(-\frac{1}{2} (x^T (\sum_{k=1}^K \Sigma_k^{-1}) x - 2x^T (\sum_{k=1}^K \Sigma_k^{-1} \mu_k) + \sum_{k=1}^K \mu_k^T \Sigma_k^{-1} \mu_k)) \dots <1>$$

在式<1>中： $x^T (\sum_{k=1}^K \Sigma_k^{-1}) x$ 为二次项

$2x^T (\sum_{k=1}^K \Sigma_k^{-1} \mu_k)$ 为一次项

可以凑出“完全平方式”

$$f_1(x)f_2(x)\dots f_K(x)$$

$$=\frac{1}{\sqrt{(2\pi)^{\sum_{k=1}^K N_k}} \prod_{k=1}^K \det(\Sigma_k)} \exp(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu) + M)$$

上式中M为一个常数;

$$f_1(x)f_2(x)\dots f_K(x)$$

$$=\frac{1}{\sqrt{(2\pi)^{\sum_{k=1}^K N_k}} \prod_{k=1}^K \det(\Sigma_k)} \exp(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)) \dots \dots \dots <2>$$

根据上式二次项一次项对应参数，可以得到：

$$\Sigma^{-1} = \sum_{k=1}^K \Sigma_k^{-1}$$

$$\Sigma^{-1} \mu = \sum_{k=1}^K \Sigma_k^{-1} \mu_k$$

为了满足归一化条件，需要将变量指数项外的其他常数项归一到 η 中，也即证明K个独立正态分布随机变量概率密度相乘归一化之后仍为正态分布

2.5.7

假设有K个互相独立的随机变量 x_k ，它们通过加权组成一个新的随机变量：

$$x = \sum_{k=1}^K \omega_k x_k$$

其中 $\sum_{k=1}^K \omega_k = 1$ 且 $\omega_k \geq 0$ ，它们的期望表示为：

$$\mu = \sum_{k=1}^K \omega_k \mu_k$$

其中 μ_k 是 x_k 的均值，请定义出一个计算方差的表达式，注意，这些随机变量并没有假设服从高斯分布

solution:

统计学上有公式：

对于独立随机变量 X, Y

$$D(\omega_x X + \omega_y Y) = \omega_x^2 D(X) + \omega_y^2 D(Y) \dots \dots <0>$$

这里假设 x_k 的方差为 σ_k^2

则方差的计算公式为：

$$\sigma^2 = \sum_{i=1}^K \omega_i^2 \sigma_i^2$$

其中 $\sum_{k=1}^K \omega_k = 1$

2.5.8

当K维随机变量x服从标准正态分布，即 $x \sim N(0, 1)$ ，则随机变量：

$y = x^T x$ 服从自由度为K的卡方分布，请证明该随机变量的均值为K，方差为2K(题目条件暗含每一维度随机变量独立同分布假设，远书为准确提及)

solution:

$$y = x_1^2 + x_2^2 + \dots + x_K^2$$

$$E(y) = E(x_1^2 + x_2^2 + \dots + x_K^2)$$

$$= E(x_1^2) + E(x_2^2) + \dots + E(x_K^2)$$

根据统计学：

$$E(X^2) = D(X) + (E(X))^2$$

因此对于任意 $1 \leq i \leq K$ ：

$$E(x_i^2) = 1 + 0 = 1$$

$$E(y) = K$$

根据Isserlis定理： $E[x_i x_j x_k x_{\ell}] = E[x_i x_j] E[x_k x_{\ell}] + E[x_i x_k] E[x_j x_{\ell}] + E[x_i x_{\ell}] E[x_j x_k]$
 $\dots <0>$

方差：

$$D(y)$$

$$= E((x_1^2 + x_2^2 + \dots + x_K^2)^2)$$

$$= E(\sum_{i=1}^K x_i^4) + 2E(\sum_{i=1, i \neq j}^K E(x_i^2 x_j^2)) \dots <1>$$

根据<0>,其中：

$$E(\sum_{i=1}^K x_i^4)$$

$$= \sum_{i=1}^K E(x_i^4)$$

$$= 3K$$

$$E(\sum_{i=1, i \neq j}^K E(x_i^2 x_j^2))$$

$$= \frac{K(K-1)}{2}$$

将上述两式带入<0>:

$$D(y) = 2K$$

线性高斯系统估计

3.6.1

考虑时间离散系统：

$$x_k = x_{k-1} + v_k, v_k \sim N(0, Q)$$

$$y_k = x_k + n_k, n_k \sim N(0, R)$$

这可以表达一辆沿x轴前进或者后退的汽车，初始状态 x_0 未知，请建立批量最小二乘的状态估计方程： $(H^T W^{-1} H) \hat{x} = H^T W^{-1} z$

solution:

7 / 13

$$= \begin{bmatrix} 2Q^{-1} & -Q^{-1} & 0 & 0 \\ -Q^{-1} & 2Q^{-1}+R^{-1} & -Q^{-1} & 0 \\ & -Q^{-1} & 2Q^{-1}+R^{-1} & -Q^{-1} \\ & & -Q^{-1} & Q^{-1}+R^{-1} \end{bmatrix}$$

$$Q>0, R>0$$

W^{-1} 对称且正定，根据(3.37)做修改，因为删除了初始状态，只需： $\text{rank}(H^T H) = \text{rank}(H^T) = NK = 5$ 就可以构成唯一解充分条件 显然满足条件

因此，该系统存在唯一解

3.6.2

使用第一题的系统，令 $Q=R=1$ ，证明： $\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H} = \begin{bmatrix} 2 & -1 & 0 & 0 & 0 \\ -1 & 3 & -1 & 0 & 0 \\ 0 & -1 & 3 & -1 & 0 \\ 0 & 0 & -1 & 3 & -1 \\ 0 & 0 & 0 & -1 & 2 \end{bmatrix}$

此时Cholesky因子是什么，才能满足 $LL^T = H^T W^{-1} H$?

solution:

证明只需将数据代入上一题目的公式中即可

这里假设：

$$L = \begin{bmatrix} L_1 & 0 & 0 & 0 & 0 \\ & L_{21} & L_2 & 0 & 0 \\ & & L_{32} & L_3 & 0 \\ & & & L_{43} & L_4 \\ & & & & L_{54} & L_5 \end{bmatrix}$$

在本问题中，L矩阵的中的每一项都是标量(0维张量)，因此：

$$L^T = \begin{bmatrix} L_1 & L_{21} & 0 & 0 & 0 \\ & L_2 & L_{32} & 0 & 0 \\ & & L_3 & L_{43} & 0 \\ & & & L_4 & L_{54} \\ & & & & L_5 \end{bmatrix}$$

将矩阵相乘：

$$LL^T = \begin{bmatrix} L_1^2 & L_1 L_{21} & 0 & 0 & 0 \\ & L_2 L_{32} & L_3^2 + L_{32}^2 & L_3 L_{43} & 0 \\ & & L_4^2 + L_{43}^2 & L_4 L_{54} & L_5^2 + L_{54}^2 \end{bmatrix}$$

从矩阵最左边开始迭代就可以结算处 L (注意这个矩阵元素的结算因为涉及多个开方，存在多个解，这里仅给出一个):

$$L = \begin{bmatrix} \sqrt{2} & 0 & 0 & 0 & -\sqrt{\frac{1}{2}} \\ & \sqrt{\frac{5}{2}} & 0 & 0 & -\sqrt{\frac{2}{5}} \\ & & \sqrt{\frac{13}{5}} & 0 & -\sqrt{\frac{5}{13}} \\ & & & \sqrt{\frac{34}{13}} & 0 \\ & & & & \sqrt{\frac{13}{34}} & \sqrt{\frac{55}{34}} \end{bmatrix}$$

3.6.3

使用第一题的系统，修改最小二乘解，假设噪声之间存在相关性：

$$E[y_k y_{\ell}] = \begin{cases} R & |k-\ell|=0 \\ R/2 & |k-\ell|=1 \\ R/4 & |k-\ell|=2 \\ 0 & \text{otherwise} \end{cases}$$

此时存在唯一的最小二乘解吗？

solution:

$$W = \begin{bmatrix} Q & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & Q & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & Q & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & Q & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & Q & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & R & R/2 & R/4 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & R/2 & R & R/2 & R/4 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & R/4 & R/2 & R & R/2 & R/4 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & R/4 & R/2 & R & R/2 & R/4 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & R/4 & R/2 & R & R/2 & R/4 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & R/4 & R/2 & R & R/2 & R/4 \end{bmatrix}$$

等价于

$$W = \begin{bmatrix} Q & 0 \\ 0 & R^{-1} \end{bmatrix}$$

其中：

$$R^{-1} = R \begin{bmatrix} 1 & 1/2 & 1/4 & 0 & 0 & 0 \\ 1/2 & 1 & 1/2 & 1/4 & 0 & 0 \\ 1/4 & 1/2 & 1 & 1/2 & 1/4 & 0 \\ 0 & 1/4 & 1/2 & 1 & 1/2 & 1/4 \\ 0 & 0 & 1/4 & 1/2 & 1 & 1/2 \\ 0 & 0 & 0 & 1/4 & 1/2 & 1 \end{bmatrix}$$

R^{-1} 可逆

因此 W^{-1} 存在

根据(3.37):

$$\text{rank}(H^T H) = \text{rank}(H^T) = N K = 5$$

存在唯一解

3.6.4

使用第一题的系统，推导卡尔曼滤波器的详细过程。本例的初始状态均值为 \check{x}_0 方差为 \check{P}_0 ，证明：稳态时先验和后验方差 \check{P} 和 \hat{P} ，当 $K \rightarrow \infty$ 为以下两个方程组的解：
 $\check{P}^2 - Q\check{P} - QR = 0$ $\hat{P}^2 + Q\hat{P} - QR = 0$

此二式是离散Riccati方程的两个不同版本，同时，解释为什么这两个二次方程仅有一个是物理上可行的。

solution:

具有先验信息的条件下：

$$H^T W^{-1} H = \begin{bmatrix} \check{P}_0^{-1} + Q^{-1} + R^{-1} & -Q^{-1} & 0 & 0 & 0 \\ -Q^{-1} & 2Q^{-1} + R^{-1} & -Q^{-1} & 0 & 0 \\ 0 & -Q^{-1} & 2Q^{-1} + R^{-1} & -Q^{-1} & 0 \\ 0 & 0 & -Q^{-1} & 2Q^{-1} + R^{-1} & -Q^{-1} \\ 0 & 0 & 0 & -Q^{-1} & 2Q^{-1} + R^{-1} \end{bmatrix}$$

$$L = \begin{bmatrix} L_0 & 0 & 0 & 0 & 0 \\ L_{10} & L_1 & 0 & 0 & 0 \\ L_{21} & L_2 & 0 & 0 & 0 \\ L_{32} & L_3 & 0 & 0 & 0 \\ L_{43} & L_4 & 0 & 0 & 0 \\ L_{54} & L_5 & 0 & 0 & 0 \end{bmatrix}$$

$$L^T = \begin{bmatrix} L_0^T & L_{10}^T & 0 & 0 & 0 \\ L_1^T & L_{21}^T & 0 & 0 & 0 \\ L_2^T & L_{32}^T & 0 & 0 & 0 \\ L_3^T & L_{43}^T & 0 & 0 & 0 \\ L_4^T & L_{54}^T & 0 & 0 & 0 \end{bmatrix}$$

$$\begin{bmatrix} L_0 & L_{10} & 0 & 0 & 0 & 0 & 0 & 0 & L_1 & L_{21} & 0 & 0 & 0 & 0 & 0 & L_2 \\ & & & & & & & & & & & & & & & L_{32} & 0 & 0 & 0 & 0 & L_3 & L_{43} & 0 & 0 & 0 & 0 & 0 & L_4 & L_{54} & 0 & 0 & 0 & 0 & 0 & L_5 \end{bmatrix}$$

对于：

$$\begin{aligned} (k=1 \dots K) \quad & \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{I}_{k-1} + \mathbf{A}_{k-1}^T \mathbf{T} \mathbf{A}_{k-1} \\ & \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{A}_{k-1} \mathbf{L}_{k-1} \mathbf{d}_{k-1} = \mathbf{q}_{k-1} - \mathbf{A}_{k-1}^T \mathbf{T} \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{Q}_{k-1} \mathbf{A}_{k-1}^T \mathbf{I}_{k-1} \mathbf{I}_{k-1} = \mathbf{I}_{k-1} \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T + \mathbf{Q}_{k-1} \mathbf{C}_{k-1}^T \mathbf{R}_{k-1} \mathbf{C}_{k-1} \mathbf{Q}_{k-1}^T \\ & \mathbf{R}_{k-1} \mathbf{C}_{k-1} \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{R}_{k-1} \mathbf{C}_{k-1} \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \end{aligned}$$

根据本系统修正：

$$\begin{aligned} (k=1 \dots K) \quad & \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{I}_{k-1} + \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \mathbf{d}_{k-1} = \mathbf{q}_{k-1} - \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \\ & \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{I}_{k-1} \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T + \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \mathbf{d}_{k-1} = \mathbf{q}_{k-1} - \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \\ & \mathbf{R}_{k-1} \mathbf{C}_{k-1} \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{R}_{k-1} \mathbf{C}_{k-1} \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \end{aligned}$$

$$\begin{aligned} & \mathbf{I}_{k-1} \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{I}_{k-1} \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T + \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \\ & \mathbf{R}_{k-1} \mathbf{C}_{k-1} \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T = \mathbf{R}_{k-1} \mathbf{C}_{k-1} \mathbf{Q}_{k-1} \mathbf{Q}_{k-1}^T \mathbf{v}_k \mathbf{L}_{k-1} \mathbf{L}_{k-1}^T \end{aligned}$$

卡尔曼滤波推导完毕

根据(3.28)

当 $K \rightarrow \infty$ 处于稳态时：

$$\check{P} = \hat{P} + Q \dots \dots \dots <0>$$

$$K = \check{P} / (\check{P} + R)^{-1} \dots \dots \dots <1>$$

$$\hat{P} = (1-K) \check{P} \dots \dots \dots <2>$$

将 <1> <2> 带入 <0>：

$$\check{P} = (1-K) \check{P} + Q = (1 - \frac{\check{P}}{\check{P} + R}) \check{P} + Q$$

整理得：

$$\check{P}^2 - Q \check{P} - QR = 0$$

将 <0> <1> 带入 <3> 得：

$$\hat{P} = (1-K)(\hat{P} + Q) = (1 - \frac{\hat{P} + Q}{\hat{P} + Q + R})(\hat{P} + Q)$$

整理得：

$$\hat{P}^2 + Q \hat{P} - QR = 0$$

3.6.5

使用3.3.2节的MAP方法，推导后向的卡尔曼滤波器(而非前向的)

solution:

反向卡尔曼滤波应该是在得到 k 时刻的控制和观测之后，对 $K-1$ 时刻的状态进行估计

根据(3.109)式，也即计算 \hat{x}_{k-1}

原理示意图参考书中3-4图

根据(3.110):

$$\hat{P}_{k-1} + A_{k-1}^T Q_k A_{k-1} \hat{x}_{k-1} - A_{k-1}^T Q_k \hat{x}_k = \hat{P}_{k-1} \hat{x}_{k-1} - A_{k-1}^T Q_k v_k \quad \text{-----} <0>$$

根据正向卡尔曼滤波器的递推公式(3.120):

带入(3.120a)(3.120b)(3.120c)(3.120e)式：

$$\hat{P}_{k-1} + A_{k-1}^T Q_k A_{k-1} \hat{x}_{k-1} = A_{k-1}^T Q_k \hat{x}_k + \hat{P}_{k-1} \hat{x}_{k-1} - A_{k-1}^T Q_k v_k$$

$$= A_{k-1}^T Q_k A_{k-1} y_k - A_{k-1}^T Q_k A_{k-1} C_k v_k + A_{k-1}^T Q_k (1 - C_k C_k) A_{k-1} \hat{x}_{k-1}$$

令：

$$K_{k,b} = \hat{P}_{k-1} + A_{k-1}^T Q_k A_{k-1} - A_{k-1}^T Q_k A_{k-1} C_k$$

$$K_{k,b,y} = K_{k,b} K_{k,b}^{-1}$$

$$K_{k,b,v} = -K_{k,b} K_{k,b}^{-1} C_k$$

$$K_{k,b,x} = K_{k,b} (1 - C_k C_k) A_{k-1}$$

由此反向卡尔曼滤波：

$$\hat{x}_{k-1} = K_{k,b,y} y_k + K_{k,b,v} v_k + K_{k,b,x} \hat{x}_{k-1}$$

上式中 y_k, v_k 融合了 k 时刻的观测和控制

\hat{x}_{k-1} 融合了 $0 \sim k-1$ 时刻的信息

3.5.6

证明：

$$\begin{aligned} & \left[\begin{array}{c} \mathbf{1} & \mathbf{A} & \mathbf{A}^2 & \dots & \mathbf{A}^{K-1} \\ \mathbf{A} & \mathbf{A}^2 & \mathbf{A}^3 & \dots & \mathbf{A}^K \\ \mathbf{A}^2 & \mathbf{A}^3 & \mathbf{A}^4 & \dots & \mathbf{A}^{K+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{A}^{K-1} & \mathbf{A}^K & \mathbf{A}^{K+1} & \dots & \mathbf{A}^{2K} \end{array} \right] = \left[\begin{array}{c} 1 & \mathbf{-A} & 1 & \mathbf{-A} & \mathbf{-A}^2 & \mathbf{-A}^3 & \mathbf{-A}^4 & \mathbf{-A}^5 & \mathbf{-A}^6 & \mathbf{-A}^7 & \mathbf{-A}^8 & \mathbf{-A}^9 & \mathbf{-A}^{10} & \mathbf{-A}^{11} & \mathbf{-A}^{12} & \mathbf{-A}^{13} & \mathbf{-A}^{14} & \mathbf{-A}^{15} & \mathbf{-A}^{16} & \mathbf{-A}^{17} & \mathbf{-A}^{18} & \mathbf{-A}^{19} & \mathbf{-A}^{20} & \mathbf{-A}^{21} & \mathbf{-A}^{22} & \mathbf{-A}^{23} & \mathbf{-A}^{24} & \mathbf{-A}^{25} & \mathbf{-A}^{26} & \mathbf{-A}^{27} & \mathbf{-A}^{28} & \mathbf{-A}^{29} & \mathbf{-A}^{30} & \mathbf{-A}^{31} & \mathbf{-A}^{32} & \mathbf{-A}^{33} & \mathbf{-A}^{34} & \mathbf{-A}^{35} & \mathbf{-A}^{36} & \mathbf{-A}^{37} & \mathbf{-A}^{38} & \mathbf{-A}^{39} & \mathbf{-A}^{40} & \mathbf{-A}^{41} & \mathbf{-A}^{42} & \mathbf{-A}^{43} & \mathbf{-A}^{44} & \mathbf{-A}^{45} & \mathbf{-A}^{46} & \mathbf{-A}^{47} & \mathbf{-A}^{48} & \mathbf{-A}^{49} & \mathbf{-A}^{50} & \mathbf{-A}^{51} & \mathbf{-A}^{52} & \mathbf{-A}^{53} & \mathbf{-A}^{54} & \mathbf{-A}^{55} & \mathbf{-A}^{56} & \mathbf{-A}^{57} & \mathbf{-A}^{58} & \mathbf{-A}^{59} & \mathbf{-A}^{60} & \mathbf{-A}^{61} & \mathbf{-A}^{62} & \mathbf{-A}^{63} & \mathbf{-A}^{64} & \mathbf{-A}^{65} & \mathbf{-A}^{66} & \mathbf{-A}^{67} & \mathbf{-A}^{68} & \mathbf{-A}^{69} & \mathbf{-A}^{70} & \mathbf{-A}^{71} & \mathbf{-A}^{72} & \mathbf{-A}^{73} & \mathbf{-A}^{74} & \mathbf{-A}^{75} & \mathbf{-A}^{76} & \mathbf{-A}^{77} & \mathbf{-A}^{78} & \mathbf{-A}^{79} & \mathbf{-A}^{80} & \mathbf{-A}^{81} & \mathbf{-A}^{82} & \mathbf{-A}^{83} & \mathbf{-A}^{84} & \mathbf{-A}^{85} & \mathbf{-A}^{86} & \mathbf{-A}^{87} & \mathbf{-A}^{88} & \mathbf{-A}^{89} & \mathbf{-A}^{90} & \mathbf{-A}^{91} & \mathbf{-A}^{92} & \mathbf{-A}^{93} & \mathbf{-A}^{94} & \mathbf{-A}^{95} & \mathbf{-A}^{96} & \mathbf{-A}^{97} & \mathbf{-A}^{98} & \mathbf{-A}^{99} \end{array} \right] \end{aligned}$$

solution:

$$\begin{aligned} & \left[\begin{array}{c} \mathbf{1} & \mathbf{A} & \mathbf{A}^2 & \dots & \mathbf{A}^{K-1} \\ \mathbf{A} & \mathbf{A}^2 & \mathbf{A}^3 & \dots & \mathbf{A}^K \\ \mathbf{A}^2 & \mathbf{A}^3 & \mathbf{A}^4 & \dots & \mathbf{A}^{K+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{A}^{K-1} & \mathbf{A}^K & \mathbf{A}^{K+1} & \dots & \mathbf{A}^{2K} \end{array} \right] \end{aligned}$$

$$\begin{bmatrix} \mathbf{A}^{K-1} & \mathbf{A}^{K-2} & \cdots & \mathbf{A} & \mathbf{1} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \mathbf{A} & \mathbf{1} & \cdots & \mathbf{A} & \mathbf{1} \end{bmatrix} \begin{bmatrix} \mathbf{x}_{K-1} \\ \mathbf{x}_{K-2} \\ \vdots \\ \mathbf{x}_1 \\ \mathbf{x}_0 \end{bmatrix} = \mathbf{E} \begin{bmatrix} \mathbf{y}_K \\ \mathbf{y}_{K-1} \\ \vdots \\ \mathbf{y}_1 \\ \mathbf{y}_0 \end{bmatrix}$$

此处 \mathbf{E} 为单位矩阵，即证

3.5.7

我们已经介绍了在批量最小二乘解中，后验协方差：

$$\hat{\mathbf{P}} = (\mathbf{H}^T \mathbf{W}^{-1} \mathbf{H})^{-1}$$

同时我们也知道，Cholesky分解：

$$\mathbf{L} \mathbf{L}^T = \mathbf{H}^T \mathbf{W}^{-1} \mathbf{H}$$

的计算代价 $O(N(K+1))$ ，这是由于系统具备稀疏性，反之，我们有：

$$\hat{\mathbf{P}} = \mathbf{L}^{-T} \mathbf{L}^{-1}$$

请说明这种计算方法计算 $\hat{\mathbf{P}}$ 的复杂度。

solution:

假设 \mathbf{L} 逆矩阵的已经计算得到，由于 $\mathbf{L} \mathbf{L}^T$ 矩阵相乘得到的特殊稀疏结构，

$\hat{\mathbf{P}}$ 为 $(K+1) \times (K+1)$ 的二维矩阵

计算 $\hat{\mathbf{P}}$ 的复杂度：

$$\text{计算频次} = N([(K+1) + [(K+1) + (K)] + \dots + [(K+1) + (K) + (K-1) + \dots + 1]] + [(K) + [(K) + (K-1)] + \dots + [(K) + (K-1) + \dots + 1]])$$

$$= N(\sum_{i=1}^{K+1} i^2 + \sum_{i=1}^K i^2)$$

$$= N(\frac{(K+1)(K+2)(2K+3)}{6} + \frac{K(K+1)(2K+1)}{6})$$

因此计算复杂度为 $O(NK^3)$

4.非线性非高斯系统的状态估计

4.6.1

考虑如下离散时间系统：

$$\begin{bmatrix} \mathbf{x}_k \\ \mathbf{y}_k \\ \boldsymbol{\theta}_k \end{bmatrix} = \begin{bmatrix} \mathbf{x}_{k-1} \\ \mathbf{y}_{k-1} \\ \boldsymbol{\theta}_{k-1} \end{bmatrix} + \mathbf{T} \begin{bmatrix} \cos \boldsymbol{\theta}_{k-1} & 0 & \sin \boldsymbol{\theta}_{k-1} & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mathbf{v}_k \\ \boldsymbol{\omega}_k \end{bmatrix} + \boldsymbol{\omega}_k$$

其中 $\boldsymbol{\omega} \sim N(0, \mathbf{Q})$

$$\begin{bmatrix} \mathbf{r}_k \\ \boldsymbol{\phi}_k \end{bmatrix} = \begin{bmatrix} \sqrt{\mathbf{x}_k^2 + \mathbf{y}_k^2} \\ \text{atan2}(-\mathbf{y}_k, -\mathbf{x}_k) - \boldsymbol{\theta}_k \end{bmatrix} + \mathbf{n}_k$$

$$\mathbf{n}_k \sim \mathcal{N}(0, R)$$

该系统可以看做移动机器人在xy平面上移动，测量值为移动机器人距离原点的距离和方位，请建立EFK方程来估计移动机器人的位姿，并写出雅可比 \mathbf{F}_{k-1} ， \mathbf{G}_k 和协方差 \mathbf{Q}_k ， \mathbf{R}_k 的表达式。

solution:

参考文献：

1. Matrix Cookbook---Kaare Brandt Petersen